

by Yung-Yi Hsu (r12227104@ntu.edu.tw)

1/5

```
K=2, accuracy=0.98
K=3, accuracy=0.96
K=4, accuracy=0.96
K=5, accuracy=0.97
```

```
In [ ]: #用不同的k值來看看用X預測打亂的Y的準確度會不會有差別
for i in range(2,6,1):
    clf3=neighbors.KNeighborsClassifier(i)
    clf3.fit(X,Y2)
    acc3=np.mean(clf3.predict(X)==Y2)
    print(f"K={i}, accuracy={round(acc3,2)}")
```

```
K=2, accuracy=0.69
K=3, accuracy=0.69
K=4, accuracy=0.61
K=5, accuracy=0.57
```

討論二

結果發現當k值增加時，以X預測Y的正確率仍非常高（皆 > 0.95）。但若將Y打散（即Y2），以X預測Y的正確率則下降到0.6-0.7左右，且有k越大正確率越低的趨勢。細節說明如下：因為已知X與Y確實存在關係（鳶尾花的品種與花萼花瓣長寬間有相關），因此即使k值增加，都能大致正確。而Y2（打散的Y）是X的隨機標籤，兩者理論上並無相關，因此k越多時，採用的無效資料點越多（除了自己都是無效點），因此正確率下降，且有k越大正確率越低的趨勢。

```
In [ ]: # 用打亂的Y訓練能預測正確的Y嗎?
import scipy.stats as stats
# shuffle Y and calculate predict accuracy
clf4=neighbors.KNeighborsClassifier(1)
acclist=[]
for i in range(30):
    Yshuffle=np.random.permutation(Y)
    clf4.fit(X,Yshuffle)
    acc = np.mean(clf4.predict(X)==Y)
    acclist.append(acc)

meanacc = np.mean(acclist)
print(round(meanacc,4))
#t-test
t = stats.ttest_1samp(a=acclist, popmean=1/3)
print(f"t({t.df}) = {round(t.statistic,4)}, p-value = {round(t.pvalue,4)}")
```

```
0.3282
t(29) = -0.6641, p-value = 0.5119
```

討論三

將X及打散後的Y作為k-NN(1-NN)的訓練資料產生模型，並拿此模型預測X對應的Y。結果發現30次訓練中，平均正確率為0.3282，與1/3(chance level) 相當接近（差異值僅約0.0051）。將30筆正確率與1/3(chance level) 做one-sample t-test，統計上沒有顯著差異（p-value = 0.5119）。細節說明如下：因為打散後的Y是X的隨機標籤，因此在預測X對應的Y上，理論上和實際上都是無效的，故正確率大致為chance level(0.33)。

結果簡述

1. 即使打散Y和X沒有相關，1-NN模型仍能正確的用X預測打散Y（自己預測自己）。2. 當k變大時，k-NN用X預測打散Y（兩者無相關）的正確率變低，而X預測Y（兩者高相關）則保持非常高的正確率。3. 若用打散Y訓練1-NN模型，然後輸入X預測Y，得到的正確率為chance level。

1.2 請用母數或無母數統計檢定以下 accuracies 中的結果是否和 chance level (0.5) 有差異? 若有, why? (4 points)

```
In [ ]: Y3=np.reminder(range(200),2)
print(Y3) #Y3的0和1個數一樣多
```

[illegible]

```
In [ ]: # 跑一百次測試:
        clf=svm.SVC()
        accuracies=[]
        for i in range(100):
            X=np.random.rand(200,2) # X取亂數
            kf=model_selection.KFold(len(Y3),shuffle=True) # Leave-one-out cross-validation
            sc=model_selection.cross_val_score(clf,X,Y3,cv=kf)
            accuracies.append(sc.mean())
```

```
In [ ]: # According to central limit theorem, the distribution of the mean of a large nu
# So, we can use t-test to test the mean of accuracies.
# t-test
from scipy.stats import ttest_1samp
t2 = ttest_1samp(accuracies,0.5)
accmean2 = np.mean(accuracies)
print(round(accmean2,4))
print(f"t({t2.df}) = {round(t2.statistic,4)}, p-value = {round(t2.pvalue,4)}")
```

0.48

$$t(99) = -2.8157, \text{ p-value} = 0.0059$$

討論一

結果發現正確率的平均值為0.48，略低於平均值 t-test結果發現有顯著差異，p-value約為0.006 因為使用Leave-one-out cross-validation，在0和1一樣多的情況下，testing data 的正確答案在training data的比例較低 (99:100)，因此在X和Y3無關的情況下，正確率會略低於chance level。

```
In [ ]: #測試不同比例的Y

Y4 = np.array([0] * 120 + [1] * 80)
Y4 = np.random.permutation(Y4)
print(Y4)
# 跑一百次測試:
clf=svm.SVC()
accuracies2=[]
for i in range(100):
    X=np.random.rand(200,2) # x取亂數
```

```

kf=model_selection.KFold(len(Y4),shuffle=True) # Leave-one-out cross-validation
sc=model_selection.cross_val_score(clf,X,Y4,cv=kf)
accuracies2.append(sc.mean())
t3 = ttest_1samp(accuracies2,0.5)
accmean3 = np.mean(accuracies2)
print(round(accmean3,4))
print(f"t({t3.df}) = {round(t3.statistic,4)}, p-value = {round(t3.pvalue,4)}")

```

```

[0 1 1 0 0 0 0 0 1 0 1 1 1 0 0 1 0 0 0 0 1 0 0 0 1 0 0 0 1 0 0 1 1 0 0 1 1
 1 0 0 1 0 0 0 1 1 0 1 0 0 0 0 0 0 0 0 0 0 0 1 1 0 0 0 0 0 0 0 0 0 0 1 1 0 0 0
 0 1 1 0 0 0 0 0 1 1 0 0 0 1 1 0 1 0 1 0 0 0 1 0 1 0 0 0 0 0 1 1 1 1 1 0 0 1
 0 0 1 1 0 0 0 0 1 0 1 1 1 0 1 0 0 1 0 0 1 0 0 0 0 0 0 0 0 0 1 0 1 1 1 1 0 0
 0 1 0 0 1 0 1 1 1 0 0 1 1 0 0 1 0 0 1 1 0 1 1 1 0 1 1 1 0 1 1 1 0 1 1 0 1 1
 1 0 0 0 0 0 1 0 1 0 1 0 0 1 0]

```

0.5846

t(99) = 28.4879, p-value = 0.0

```

In [ ]: Y5 = np.array([0] * 150 + [1] * 50)
Y5 = np.random.permutation(Y5)
print(Y5)
# 跑一百次測試:
clf=svm.SVC()
accuracies3=[]
for i in range(100):
X=np.random.rand(200,2) # X取亂數
kf=model_selection.KFold(len(Y5),shuffle=True) # Leave-one-out cross-validation
sc=model_selection.cross_val_score(clf,X,Y5,cv=kf)
accuracies3.append(sc.mean())
t4 = ttest_1samp(accuracies3,0.5)
accmean4 = np.mean(accuracies3)
print(round(accmean4,4))
print(f"t({t4.df}) = {round(t4.statistic,4)}, p-value = {round(t4.pvalue,4)}")

```

```

[0 0 1 0 0 0 1 1 0 0 0 0 0 0 0 1 0 0 1 0 0 0 1 0 1 0 1 0 1 1 1 1 1 0 0 0 1
 0 0 0 1 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 0 0 0 0 0 0 0 0 0 1 0
 0 0 0 0 0 1 0 0 0 0 0 0 0 1 1 1 0 1 0 0 0 0 0 1 0 0 1 0 1 0 0 0 0 0 1 0 0 1 0
 0 0 0 0 1 1 0 0 0 0 0 0 0 1 0 0 0 1 0 1 0 0 1 0 1 0 0 0 1 0 0 0 0 0 0 0 1 0
 0 1 0 0 0 1 0 0 0 0 1 0 0 0 0 0 0 0 1 0 0 0 0 0 0 1 0 0 0 0 1 1 0 1 0 1 0
 0 1 0 0 0 0 0 0 0 1 0 0 0 0 0]

```

0.7496

t(99) = 935.3144, p-value = 0.0

討論二

試著用0和1的比例不同的Y和亂數X來進行Leave-one-out cross-validation。在0和1的比例為3:2時(Y4, 120:80)，正確率的平均值為0.5846；在0和1的比例為3:1時(Y5, 150:50)，正確率的平均值為0.7496。發現比例越不平衡時，正確率越高。細節說明：當Y的比例越不平衡時，在X和Y無關的情況下，模型應該越有高的傾向將資料歸類為數量多的類別(模型中為0)，同時數量多的類別(0)是testing data的正確答案的比例也越高，因此正確率越高。

```

In [ ]: Y6 = np.array([0] * 100 + [1] * 100 + [2] * 100)
Y6 = np.random.permutation(Y6)
print(Y6)
# 跑一百次測試:
clf=svm.SVC()
accuracies4=[]
for i in range(100):

```

```

X=np.random.rand(300,2) # X取亂數
kf=model_selection.KFold(len(Y6),shuffle=True) # Leave-one-out cross-validation
sc=model_selection.cross_val_score(clf,X,Y6,cv=kf)
accuracies4.append(sc.mean())
t5 = ttest_1samp(accuracies4,1/3)
accmean5 = np.mean(accuracies4)
print(round(accmean5,4))
print(f"t({t5.df}) = {round(t5.statistic,4)}, p-value = {round(t5.pvalue,4)}")

```

```

[1 2 2 1 2 1 0 1 2 2 0 0 0 2 2 1 0 0 0 0 2 2 1 1 1 0 2 1 2 0 0 0 1 0 0 1 2
 2 1 2 2 2 0 1 2 2 2 1 1 2 1 2 0 2 0 0 2 0 0 2 1 1 0 1 2 1 1 0 1 0 1 1 1 0
 1 1 0 1 0 2 1 2 2 1 2 0 2 1 1 0 2 1 1 2 1 1 0 0 2 1 1 2 0 0 0 0 1 0 1 1 1
 0 2 0 2 1 2 1 2 1 2 2 2 0 1 0 1 2 1 0 1 2 0 2 0 2 0 0 1 1 0 0 1 1 2 0 2 0
 1 0 1 2 2 2 1 0 0 0 2 0 2 1 2 2 0 0 0 0 0 2 2 0 2 0 1 1 0 2 0 0 1 0 2 2 1
 0 1 0 1 2 0 0 2 1 2 0 0 0 1 2 2 2 1 2 1 1 1 0 0 1 2 1 2 2 1 2 2 2 1 2 1 2
 0 1 1 2 1 1 0 1 2 1 0 2 1 0 0 2 1 1 0 2 2 2 1 2 2 0 1 2 0 2 0 1 2 1 0 2 1
 0 2 0 0 1 2 0 2 0 1 2 2 1 2 0 1 2 0 0 0 1 0 0 0 2 1 2 1 0 0 0 1 2 2 0 1 2
 1 0 1 1]
0.312
t(99) = -4.5837, p-value = 0.0

```

In []: `print(t5)`

```
TtestResult(statistic=-4.583748905283841, pvalue=1.3354060839215416e-05, df=99)
```

討論三

測試當Y有等量三類別時，和亂數X來進行Leave-one-out cross-validation的正確率 結果發現平均正確率為0.312，統計上達顯著($t(99) = -4.5831$, $p\text{-value} < 0.0001$) 與我在討論一中說明的預期結果相符 (Y比例一致時，正確率會顯著略低於平均)

總結論

當X和Y無關時，用Leave-one-out cross-validation建立X預測Y模型的正確率受Y中類別的比例影響。如果Y是等比例的，正確率會略低於chance level；而當Y的比例越懸殊時，正確率越高。

Please submit your notebook in PDF to NTU Cool by next Friday (11/10).