Psychoinformatics - Week 10 (Exercises)

by boyonglin (r10945002@ntu.edu.tw)

1 執行並觀察以下的機器學習結果 (2分)

1.0 IRIS dataset & Ensemble model function


```
In [ ]: | iris = datasets.load_iris()
        X=iris.data
        Y=iris.target
In [ ]: np.random.seed(0)
        sss=model selection.StratifiedShuffleSplit(n splits=5,test size=0.1)
        def EnsembleModels(og_model, Max_n_estimators):
            accs=[] # mean cross-validation accuracies of the models w/ different n_estimat
            for n in range(1,Max_n_estimators+1):
                if n\%10 == 0:
                    print('"',end=' ') # showing progress
                acc=[] # cross-validation accuracies of the ensemble model w/ n_estimators=
                for train_index, test_index in sss.split(X, Y): # 5-fold cross-validation of
                    X_train, X_test = X[train_index], X[test_index]
                    Y_train, Y_test = Y[train_index], Y[test_index]
                    model=copy.deepcopy(og_model) # to avoid possible model re-training
                    model.n estimators=n
                    model.fit(X_train[:,0:2],Y_train) #training
                    acc.append(model.predict(X_test[:,0:2])==Y_test)
                accs.append(np.mean(acc)) # aggregating mean cross-validation accuracies ac
            return(accs)
```

1.1 Bagging (Bootstrap Aggregating)


1.1.1 Tree max_depth = 1

```
In [ ]: model=ensemble.BaggingClassifier(tree.DecisionTreeClassifier(max_depth=1))
    accs=EnsembleModels(model,100)
```

```
plot(range(1,101),accs)
print('mean accuracy:',np.mean(accs))
```




1.1.2 Tree max_depth = 3



1.2 Boosting

1.2.1 AdaBoost


1.2.1.1 Tree max_depth = 1



1.2.1.2 Tree max_depth = 3

```
In [ ]: model=ensemble.AdaBoostClassifier(tree.DecisionTreeClassifier(max_depth=3))
    accs=EnsembleModels(model,100)
    plot(range(1,101),accs)
    print('mean accuracy:',np.mean(accs))

    # # # # # # mean accuracy: 0.7170666666666667
```




1.2.2 Gradient Boosting


The following two implementations are conceptually identical but XGBoost is more resource-efficient and can be parallelized/distributed.

1.2.2.1 Scikit-learn's Gradient Tree Boosting

1.2.2.1.1 Tree max_depth = 1




1.2.2.1.2 Tree max_depth = 3




1.2.2.2 XGBoost (eXtreme Gradient Boosting)

1.2.2.2.1 Tree max_depth = 1



1.2.2.2.2 Tree max_depth = 3



2 根據以上的觀察回答以下的問題 (6分)

2.1 在Bagging時, 1.1.2中複雜模型的正確率是否比 1.1.1簡單模型的正確率好或差? 為什麼 (2分)

在 Bagging 中·複雜模型的正確率比簡單模型高。因為 Bagging 的核心思想是透過對訓練數據的隨機抽樣 (Bootstrap 抽樣)生成多個不同的子樣本·然後分別在這些子樣本上訓練獨立,最後做預測並平均。

高複雜性的 Bagging 模型相對較容易在不同的子樣本上產生差異化的預測,從而增加集成模型的多樣性,與提高模型的穩定性。

2.2 在Boosting時, 1.2.1.2/1.2.2.1.2/1.2.2.2.2中複雜 模型的正確率是否比1.2.1.1/1.2.2.1.1/1.2.2.2.1中相對 應的簡單模型正確率好或差? 為什麼 (2分)

AdaBoost 複雜模型比簡單模型正確率高,因為在複雜 AdaBoost 中,當前一輪的弱學習器錯誤分類的樣本權重會增加,這樣這些樣本在下一輪的訓練中會變得更加重要。

Gradient Boosting 則相反,複雜模型比簡單模型正確率低,因為 Gradient Boosting 是通過 迭代地擬合 residual 來進行模型訓練的,每個新的弱學習器都被設計來減小前一輪弱學習器的發差,而不是像AdaBoost那樣專注於先前分類錯誤的樣本。

2.3 為何只有Boosting在簡單模型時 (1.2.1.1/1.2.2.1.1/1.2.2.2.1),正確率大致上會隨著 n_estimators數目變多而增加,但Bagging和複雜的 Boosting模型卻不是如此? (2分)

在簡單模型下·Boosting 的弱學習器之間的差異性較小·因此增加弱學習器的數量可以增加模型的多樣性·從而提高模型的準確性。

而 Bagging 和複雜的 Boosting 模型已經具有足夠的多樣性,增加弱學習器的數量對模型的準確性影響不大。此外,增加弱學習器的數量也會增加計算時間和內存消耗,因此需要在準確性和效率之間進行權衡。